

Plan eksperymentów

Michał Iwaniuk, Bartłomiej Borycki

November 2025

1 Rozpatrywane konfiguracje hiperparametrów

1.1 Architektura

Przyjmijmy następujące oznaczenia

- l^t – liczba warstw enkodera (liczba bloków Transformer).
- d^h – rozmiar wektora ukrytego (*hidden size*)
- d^f – rozmiar warstwy pośredniej w feed-forward network (FFN), często nazywany *intermediate size*. W klasycznym BERT zwykle wynosi $4 \cdot d^h$.
- h – liczba głowic w mechanizmie wielogłowicowej uwagi.
- $d^{q|k|v}$ – wymiar przestrzeni zapytań (*query*), kluczy (*key*) oraz wartości (*value*) w każdej głowicy uwagi. (W klasycznym BERT przyjmuje się zazwyczaj $d^q = d^k = d^v = \frac{d^h}{h}$)

1.2 Wspólne parametry treningowe

Architektura: MLP dropout: 0.1, Embedding dropout: 0.1, Pozy-cje: `rope` (base=10000, scale=1.0). Atencja: `projection_bias=true`, `attn_out_dropout=0.1`, `attn_dropout=0.0`.

MLM head: `tie_mlm_weights=true`, `mask_p=0.15`, `mask_token_p=0.8`, `random_token_p=0.1`.

Classification head: `num_labels=2`, `classifier_dropout=0.1`, `pooling=cls`, `pooler_type=bert`.

Trening: `batch=32` (`seq_len=512`) / 2 (`seq_len=8192`), `lr=2e-5`, `warmup=0.1`, `wd=0.01`, `max_grad_norm=1.0`, `grad_accum=1`, `AMP=true`, `loss=cross_entropy`.

1.3 Architektura Bazowa

Jako standardowa architektura małego modelu BERT przyjmujemy $BERT_{SMALL}$ opisana w artykule *Well-Read Students Learn Better: On the Importance of Pre-training Compact Models*

$BERT_{SMALL}$:

l^t	d^h	d^f	h	$d^{q k v}$
4	512	2048	8	512

1.4 Szukanie optymalnych parametrów

W oparciu o architekturę bazową przeprowadzimy eksperymenty mające na celu wyznaczenie optymalnych hiperparametrów dla mechanizmów *FAVOR+* oraz LSH, które zostaną następnie wykorzystane w fazie właściwego treningu. Optymalizacja obejmie następujące parametry:

- **Mechanizm *FAVOR+*:** Optymalizacji poddany zostanie hiperparametr `nb_features`, określający liczbę ortogonalnych wektorów projekcyjnych. Rozpatrzone zostaną wartości proporcjonalne do wymiaru d_k głowy uwagi: $0.5d_k$, $1.0d_k$, $2.0d_k$ oraz $4.0d_k$.
- **Mechanizm LSH (*Locality-Sensitive Hashing*):** Analizie poddane zostaną trzy kluczowe parametry:
 - **Rozmiar fragmentu (m):** Testowane wartości to 32, 64 oraz 128.
 - **Liczba funkcji haszujących (`num_hashes`):** Sprawdzane zostaną konfiguracje z 4 oraz 8 haszami.
 - **Maskowanie wewnątrz fragmentu (`mask_within_chunks`):** Parametr logiczny, gdzie:
 - * **True:** zapytania (*queries*) wewnątrz fragmentu mogą zwracać uwagę (*attend*) wyłącznie na klucze z tego samego kubelka LSH w obrębie okna.
 - * **False:** zapytania mogą zwracać uwagę na dowolny klucz w obrębie okna.

2 Architektura właściwa (do klasyfikacji)

Wykorzystamy architektury modeli wyłonione w artykule *AutoTinyBERT: Automatic Hyper-parameter Optimization for Efficient Pre-trained Language Models* jako podstawę do treningu właściwych modeli klasyfikacyjnych.

Na powyższych architekturach przeprowadzone zostaną procesy uczenia dla

- SDPA,

l^t	d^h	d^f	h	$d^{q k v}$
5	564	1054	8	512
4	396	624	6	384
4	432	384	4	256
3	320	608	4	256

- **FAVOR** (z wykorzystaniem optymalnych parametrów wyznaczonych w poprzednim etapie),
- **LSH** (z wykorzystaniem optymalnych parametrów wyznaczonych w poprzednim etapie).

Dodatkowo, w celu stworzenia punktu odniesienia (*baseline*), wszystkie trzy wymienione typy uwagi (SDPA, FAVOR, LSH) zostaną wytrenowane również na architekturze bazowej $BERT_{SMALL}$.

Taki sposób przeprowadzenia eksperymentów ma na celu weryfikację czy wskazane architektury faktycznie zapewniają najkorzystniejszy stosunek szybkości działania do jakości predykcji również w przypadku metod FAVOR i LSH, analogicznie jak ma to miejsce w standardowych modelach BERT.

3 Trening

3.1 Korpus Wikipedii do pretreningu MLM

Wybrano podzbiór ok. 200 000 artykułów.

Wybierane dokumenty zawierające przynajmniej jedno ze słów kluczowych:

["film", "sport", "business", "science", "technology", "news"]

3.2 TAPT + Fine-tuning(klasyfikacja): IMDB, AG News i korpus ArXiv

- **IMDB:** seq_len=512
- **AG News:** seq_len=512
- **ArXiv Classification:** seq_len=8192

4 Podsumowanie

- Każdy z trzech mechanizmów uwagi (SDPA, FAVOR, LSH) zostanie pretrenowany w pięciu wariantach architektury (bazowy $BERT_{SMALL}$ oraz cztery konfiguracje z AutoTinyBERT). Co daje łącznie **15 modeli**.

- Po procesie TAPT + Fine-tuning trzymamy łącznie **45 finalnych modeli** , co przełoży się na 45 wyników klasyfikacji podlegających późniejszej analizie.

4